ЦЕЛЬ РАБОТЫ

- Получение практических навыков численного определения количества информации, содержащегося в сообщении.
- Освоение методов построения кодов дискретного источника информации используя конструктивный метод, предложенный К. Шенноном и Н. Фано, и метод Хаффмана.

ЧАСТЬ 1

ИСХОДНЫЕ ДАННЫЕ

Текст: Преступление и наказание Ф.М. Достоевский
Отрывок Часть 1-I От слов "В начале июля" до "И я, целый месяц..."

ХОД РАБОТЫ

Таблица с посчитанными значениями по формулам

$$p_i = \frac{k_i}{K}$$
$$I_i = -\log_2 p_i$$
$$I_{cp} = \sum pi * I_i$$

$k_i -$ Количество вхождений символа в текст

$K -$ Всего символов

№ п/п	***Символ***	***Код символа***	***Число вхождений символа в текст***	***Вероятность вхождения символа (p_i)***	***I_i***
1	а	224	807	0,05844438	4,096791886
2	б	225	214	0,015498262	6,011749763
3	в	226	473	0,034255504	4,867520376
4	г	227	167	0,012094438	6,369512457
5	д	228	314	0,02274044	5,458596
6	е	229	914	0,066193511	3,917166394
7	ё	184	17	0,00123117	9,665753908
8	ж	230	126	0,009125145	6,775936826
9	з	231	184	0,013325608	6,229654793
10	и	232	677	0,049029548	4,350204726
11	й	233	113	0,008183662	6,933037787
12	к	234	394	0,028534183	5,13116493
13	л	235	542	0,039252607	4,671067708
14	м	236	382	0,027665122	5,175787921
15	н	237	689	0,04989861	4,324856576

16	о	238	1304	0,094438007	3,404488595
17	п	239	289	0,020929896	5,578291067
18	р	240	481	0,034834878	4,843323665
19	с	241	551	0,039904403	4,647308241
20	т	242	678	0,04910197	4,348075286
21	у	243	348	0,025202781	5,310273253
22	ф	244	6	0,000434531	11,16825425
23	х	245	118	0,008545771	6,8705737
24	ц	246	67	0,00485226	7,687127559
25	ч	247	176	0,012746234	6,293785131
26	ш	248	99	0,007169757	7,123860129
27	щ	249	44	0,003186559	8,293785131
28	ъ	250	1	7,24218E-05	13,75321675
29	ы	251	183	0,013253187	6,237516911
30	ь	252	204	0,014774044	6,080791407
31	э	253	46	0,003331402	8,229654793
32	ю	254	94	0,006807648	7,198627898
33	я	255	259	0,018757242	5,736408461
34	.	46	224	0,01622248	5,945861827
35	,	44	284	0,020567787	5,60346963
36	:	58	12	0,000869061	10,16825425
37	;	59	7	0,000506952	10,94586183
38	-	45	39	0,00282445	8,46781453
39		32	2169	0,157082851	2,670402412
40	«	171	13	0,000941483	10,05277703
41	»	187	13	0,000941483	10,05277703
42	!	33	21	0,001520857	9,360899326
43	?	63	10	0,000724218	10,43128865
44	—	151	55	0,003983198	7,971857036
		Всего символов в тексте (K)	13808	1	
			Полная вероятность(P)	***Энтропия источника ($I_{ср}$)***	4,573171456

Таблица 2

	Неопределенность	Разрядность кода	Абсолютная избыточность	Относительная избыточность
При кодировании сообщения стандартной кодовой таблицей ASCII	8	8	3,426828544	0,428353568
При использовании равномерного кода, построенного на основе меры Хартли	5,459431619	6	1,426828544	0,261351116

Вывод на основе анализа таблицы 2:

- При использовании кодовой таблицы ASCII избыточность практически в 2 раза больше, чем при использовании кода на основе Хартли.

ЧАСТЬ 2

ИСХОДНЫЕ ДАННЫЕ

Список символов с вероятностями из прошлой части

Значение энтропии источника $I_{ср} = 4{,}573171456$

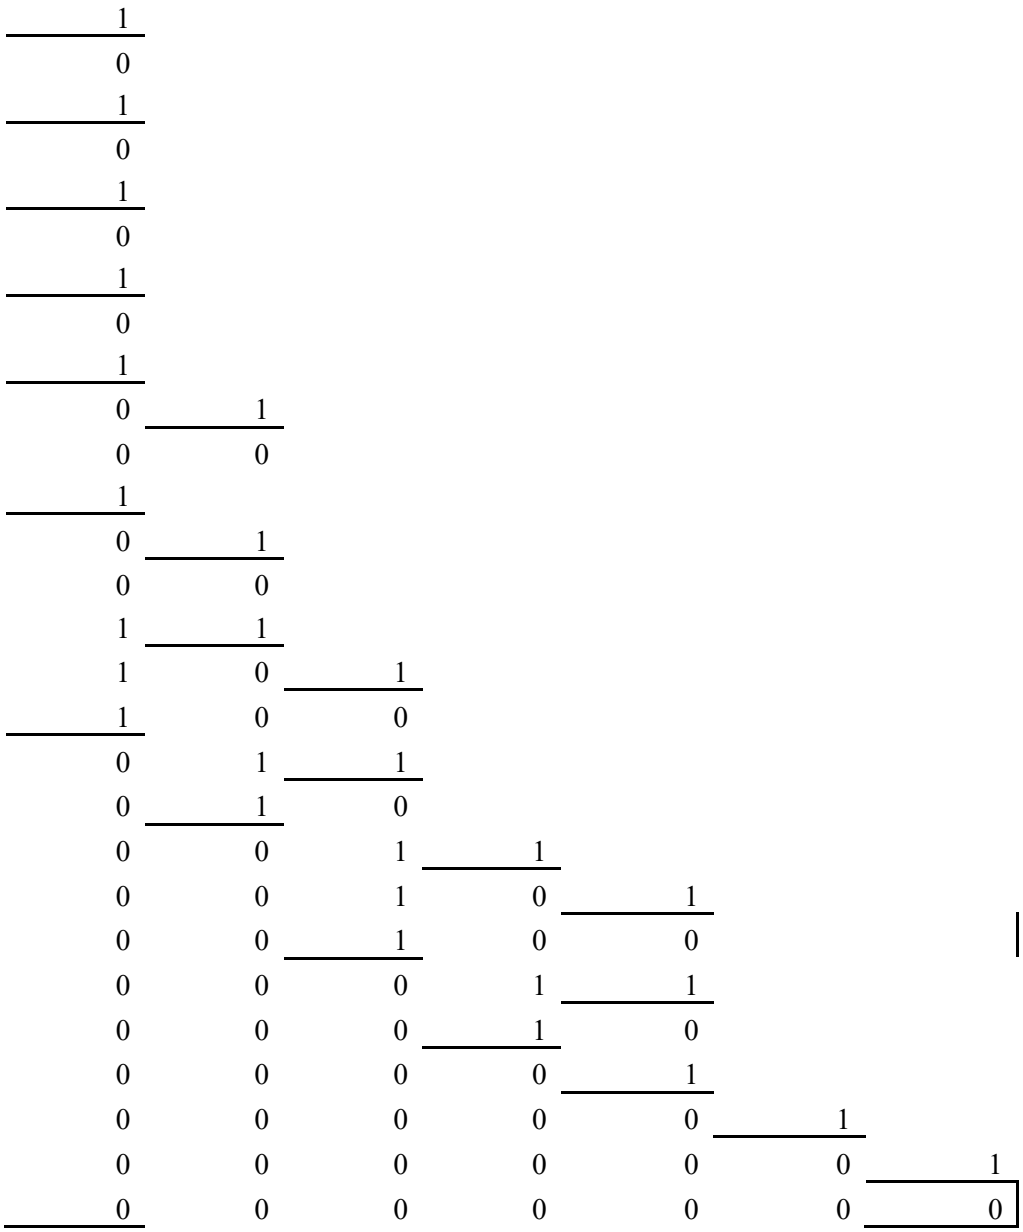
ХОД РАБОТЫ

Таблица делений по методу Шеннона-Фано

№ п/п	***Символ***	***Вероятность вхождения символа (p_i)***	Ступень 1	Ступень 2	Ступень 3	Ступень 4	Ступень 5
1		0,157082851	1	1	1		
2	о	0,094438007	1	1	0		
3	е	0,066193511	1	0	1	1	
4	а	0,05844438	1	0	1	0	
5	н	0,04989861	1	0	0	1	
6	т	0,04910197	1	0	0	0	1
7	и	0,049029548	1	0	0	0	0
8	с	0,039904403	0	1	1	1	1
9	л	0,039252607	0	1	1	1	0
10	р	0,034834878	0	1	1	0	1
11	в	0,034255504	0	1	1	0	0
12	к	0,028534183	0	1	0	1	1
13	м	0,027665122	0	1	0	1	0
14	у	0,025202781	0	1	0	0	1
15	д	0,02274044	0	1	0	0	0
16	п	0,020929896	0	0	1	1	1

17	,	0,020567787	0	0	1	1	0
18	я	0,018757242	0	0	1	1	0
19	.	0,01622248	0	0	1	0	1
20	б	0,015498262	0	0	1	0	1
21	ь	0,014774044	0	0	1	0	0
22	з	0,013325608	0	0	1	0	0
23	ы	0,013253187	0	0	0	1	1
24	ч	0,012746234	0	0	0	1	1
25	г	0,012094438	0	0	0	1	0
26	ж	0,009125145	0	0	0	1	0
27	х	0,008545771	0	0	0	1	0
28	й	0,008183662	0	0	0	0	1
29	ш	0,007169757	0	0	0	0	1
30	ю	0,006807648	0	0	0	0	1
31	ц	0,00485226	0	0	0	0	0
32	—	0,003983198	0	0	0	0	0
33	э	0,003331402	0	0	0	0	0
34	щ	0,003186559	0	0	0	0	0
35	-	0,00282445	0	0	0	0	0
36	!	0,001520857	0	0	0	0	0
37	ё	0,00123117	0	0	0	0	0
38	«	0,000941483	0	0	0	0	0
39	»	0,000941483	0	0	0	0	0
40	:	0,000869061	0	0	0	0	0
41	?	0,000724218	0	0	0	0	0
42	;	0,000506952	0	0	0	0	0
43	ф	0,000434531	0	0	0	0	0
44	ъ	7,24218E-05	0	0	0	0	0

Ступень 6	Ступень 7	Ступень 8	Ступень 9	Ступень 10	Ступень 11	Ступень 12



Значение кол-ва двоичных разрядов: 4,617033604
Значение энтропии источника: 4,573171456

Количество двочиных разрядов расчитано по формуле:

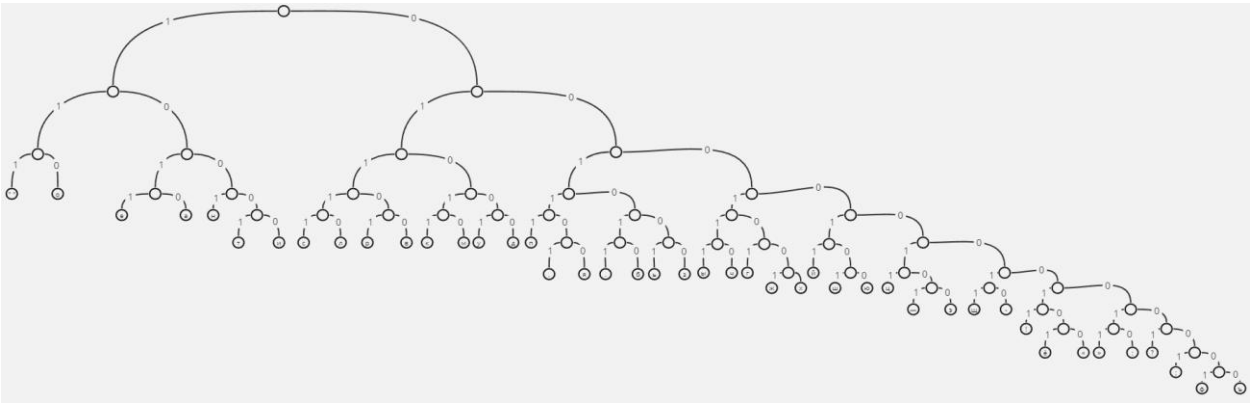
$$n_{cp} = \sum p_i * n_i$$

p_i – Вероятность символа

n_i – Разрядность кода символа

Кодовое дерево, построенное на основе кода, который получен по методу Шеннона-Фано

https://miro.com/app/board/uXjVNJN9ypA=/?share_link_id=505425677011



Кодовая таблица символов

	111	в	01100	ь	001001	ц	0000011	?	0000000001
о	110	к	01011	з	001000	—	00000101	;	00000000001
е	1011	м	01010	ы	000111	э	00000100	ф	000000000001
а	1010	у	01001	ч	000110	щ	00000011	ъ	000000000000
н	1001	д	01000	г	000101	-	00000010		
т	10001	п	00111	ж	0001001	!	000000011		
и	10000	,	001101	х	0001000	ё	0000000101		
с	01111	я	001100	й	000011	«	0000000100		
л	01110	.	001011	ш	0000101	»	0000000011		
р	01101	б	001010	ю	0000100	:	0000000010		

Пример декодирования:

Закодированое слово:

жук-барабанщик

000100101001010110000001000101010100110110100010101010100100000011100000101 1

Начинаем процесс декодирования посимвольно перебирая закодированное слово

Текущий код	Количество совпадений

000	22
0001	5
00010	3
000100	2
0001001	ж
010	4
0100	2
01001	у
010	4
0101	2
01011	к
000	22
0000	17
00000	14
000000	11
0000001	2
00000010	-
001	7
0010	4
00101	2
001010	б
101	2
1010	а
011	4

0110	2
01101	р
101	2
1010	а
001	7
0010	4
00101	2
001010	б
101	2
1010	а
100	3
1001	н
000	22
0000	17
00000	14
000000	11
0000001	2
00000011	щ
100	3
1000	2
10000	и
010	4
0101	2
01011	к

Полученное декодированное сообщение – жук-барабанщик

Сообщение однозначно декодировано.

Вывод:

- Освоен метод Шеннона-Фано по постройке кодовой таблицы с однозначным кодированием.
- Среднее количество двоичных разрядов близко к энтропии и намного меньше неопределённости по Хартли, что соответсвует тому, что скорее всего код был составлен наиболее эффективным.

ЧАСТЬ 3

ИСХОДНЫЕ ДАННЫЕ

Значение кол-ва двоичных разрядов(средней информации): 4,617033604

ХОД РАБОТЫ

Таблица сложения вероятностей по Хаффману(неполная).

№ п/п	***Символ***	***Вероятность вхождения символа (p_i)***	Вспомогательные вычисления				
			Шаг 1	Шаг 2	Шаг 3	Шаг 4	Шаг 5
1		0,157082851	0,15708	0,15708	0,15708	0,15708	0,15708
2	о	0,094438007	0,09444	0,09444	0,09444	0,09444	0,09444
3	е	0,066193511	0,06619	0,06619	0,06619	0,06619	0,06619
4	а	0,05844438	0,05844	0,05844	0,05844	0,05844	0,05844
5	н	0,04989861	0,0499	0,0499	0,0499	0,0499	0,0499
6	т	0,04910197	0,0491	0,0491	0,0491	0,0491	0,0491
7	и	0,049029548	0,04903	0,04903	0,04903	0,04903	0,04903
8	с	0,039904403	0,0399	0,0399	0,0399	0,0399	0,0399
9	л	0,039252607	0,03925	0,03925	0,03925	0,03925	0,03925
10	р	0,034834878	0,03483	0,03483	0,03483	0,03483	0,03483
11	в	0,034255504	0,03426	0,03426	0,03426	0,03426	0,03426
12	к	0,028534183	0,02853	0,02853	0,02853	0,02853	0,02853
13	м	0,027665122	0,02767	0,02767	0,02767	0,02767	0,02767
14	у	0,025202781	0,0252	0,0252	0,0252	0,0252	0,0252
15	д	0,02274044	0,02274	0,02274	0,02274	0,02274	0,02274
16	п	0,020929896	0,02093	0,02093	0,02093	0,02093	0,02093
17	,	0,020567787	0,02057	0,02057	0,02057	0,02057	0,02057
18	я	0,018757242	0,01876	0,01876	0,01876	0,01876	0,01876
19	.	0,01622248	0,01622	0,01622	0,01622	0,01622	0,01622
20	б	0,015498262	0,0155	0,0155	0,0155	0,0155	0,0155
21	ь	0,014774044	0,01477	0,01477	0,01477	0,01477	0,01477
22	з	0,013325608	0,01333	0,01333	0,01333	0,01333	0,01333
23	ы	0,013253187	0,01325	0,01325	0,01325	0,01325	0,01325
24	ч	0,012746234	0,01275	0,01275	0,01275	0,01275	0,01275

25	г	0,012094438	0,01209	0,01209	0,01209	0,01209	0,01209
26	ж	0,009125145	0,00913	0,00913	0,00913	0,00913	0,00913
27	х	0,008545771	0,00855	0,00855	0,00855	0,00855	0,00855
28	й	0,008183662	0,00818	0,00818	0,00818	0,00818	0,00818
29	ш	0,007169757	0,00717	0,00717	0,00717	0,00717	0,00717
30	ю	0,006807648	0,00681	0,00681	0,00681	0,00681	0,00681
31	ц	0,00485226	0,00485	0,00485	0,00485	0,00485	0,00485
32	—	0,003983198	0,00398	0,00398	0,00398	0,00398	0,00398
33	э	0,003331402	0,00333	0,00333	0,00333	0,00333	0,00333
34	щ	0,003186559	0,00319	0,00319	0,00319	0,00319	0,00319
35	-	0,00282445	0,00282	0,00282	0,00282	0,00282	0,00282
36	!	0,001520857	0,00152	0,00152	0,00159	0,00188	0,00225
37	ё	0,00123117	0,00123	0,00123	0,00152	0,00159	0,00188
38	«	0,000941483	0,00094	0,00101	0,00123	0,00152	0,00159
39	»	0,000941483	0,00094	0,00094	0,00101	0,00123	0,00152
40	:	0,000869061	0,00087	0,00094	0,00094	0,00101	
41	?	0,000724218	0,00072	0,00087	0,00094		
42	;	0,000506952	0,00051	0,00072			
43	ф	0,000434531	0,00051				
44	ъ	7,24218E-05					

Шаг 39	Шаг 40	Шаг 41	Шаг 42	Шаг 43	Код	Разряд	Части суммы
0,26622	0,32532	0,40846	0,59154	1	110	3	0,471248552
0,21589	0,26622	0,32532	0,40846		000	3	0,283314021
0,19257	0,21589	0,26622			1001	4	0,264774044
0,16824	0,19257				0111	4	0,23377752
0,15708					0100	4	0,199594438
					0011	4	0,196407879
					0010	4	0,196118192
					11101	5	0,199522016
					11100	5	0,196263036
					10110	5	0,174174392
					10101	5	0,17127752
					10000	5	0,142670915
					01100	5	0,138325608
					01010	5	0,126013905
					111110	6	0,136442642
					111101	6	0,125579374
					111100	6	0,123406721
					101110	6	0,112543453
					101000	6	0,097334878
					100011	6	0,092989571
					011011	6	0,088644264
					011010	6	0,07995365
					010110	6	0,079519119

					1111111	7	0,089223638
					1111110	7	0,084661066
					1011110	7	0,063876014
					1010011	7	0,059820394
					1010010	7	0,057285632
					1000100	7	0,050188297
					0101111	7	0,047653534
					10111110	8	0,038818076
					10001010	8	0,031865585
					01011101	8	0,026651217
					01011100	8	0,025492468
					101111110	9	0,025420046
					1011111110	10	0,015208575
					1000101111	10	0,012311703
					1000101101	10	0,009414832
					1000101100	10	0,009414832
					10111111111	11	0,009559676
					10111111110	11	0,007966396
					10001011101	11	0,005576477
					100010111001	12	0,005214368
					100010111000	12	0,000869061

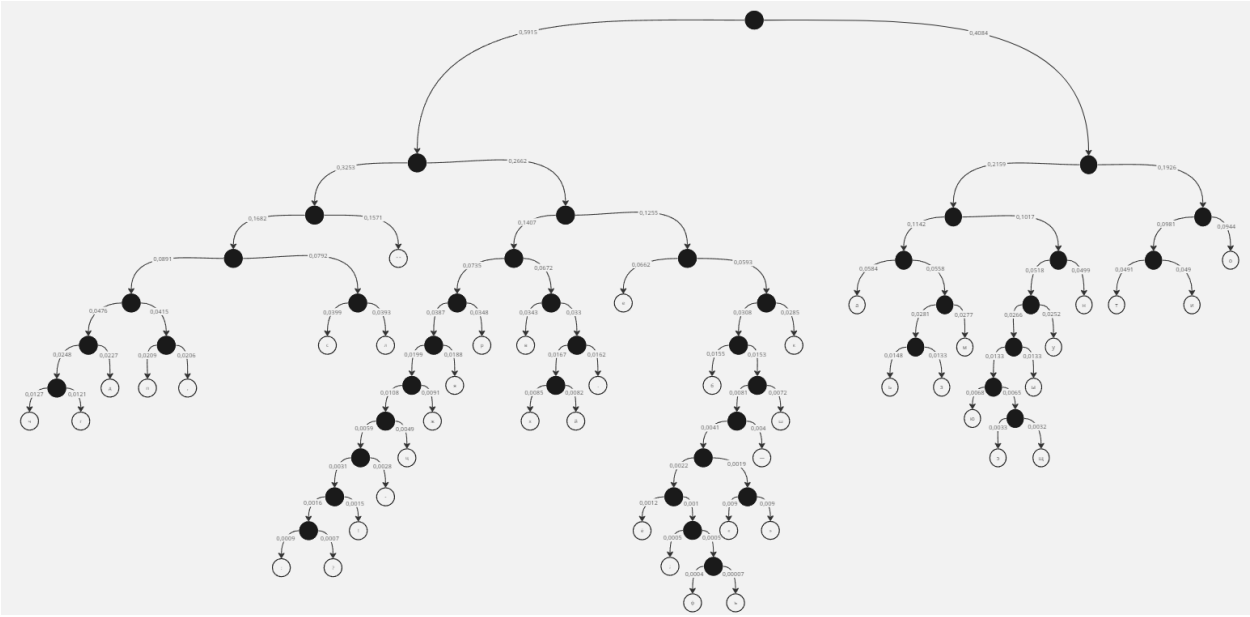
Рассчитанное количество средней информации: 4,606387601

Таблица кодов, полученная по алгоритму Хаффмана.

	110	в	10101	ь	011011	ц	10111110	?	10111111110
о	000	к	10000	з	011010	—	10001010	;	10001011101
е	1001	м	01100	ы	010110	э	01011101	ф	100010111001
а	0111	у	01010	ч	1111111	щ	01011100	ъ	100010111000
н	0100	д	111110	г	1111110	-	101111110		
т	0011	п	111101	ж	1011110	!	1011111110		
и	0010	,	111100	х	1010011	ё	1000101111		
с	11101	я	101110	й	1010010	«	1000101101		
л	11100	.	101000	ш	1000100	»	1000101100		
р	10110	б	100011	ю	0101111	:	10111111111		

Кодовое дерево

https://miro.com/app/board/uXjVNP8cfEg=/



Пример декодирования:

Закодированое слово:

жук-барабанщик

101111001010100001011111101000110111101100111100011011101000101110000101000O

Начинаем процесс декодирования посимвольно перебирая закодированное слово

Текущий код	Количество совпадений
101	12
1011	8
10111	6
101111	5
1011110	ж
010	6
0101	5
01010	у
100	11

1000	10
10000	к
101	12
1011	8
10111	7
101111	6
1011111	5
10111111	4
101111110	-
100	11
1000	10
10001	9
100011	б
011	4
0111	а
101	12
1011	8
10110	р
011	4
0111	а
100	11
1000	10
10001	9
100011	б

011	4
0111	а
010	6
0100	н
010	6
0101	5
01011	4
010111	3
0101110	2
01011100	щ
001	2
0010	и
100	11
1000	10
10000	к

Полученное декодированное сообщение – жук-барабанщик

Сообщение однозначно декодировано.

Выводы:

- Освоен метод Хаффмана по постройке кодовой таблицы с однозначным кодированием.
- Среднее количество двоичных разрядов близко к энтропии и меньше среднего количества информации по Шеннону-Фано, что соответствует тому, что скорее всего код был составлен наиболее эффективным.
- Наиболее эффективным методом кодирования информации оказался метод Хаффмана, так как среднее количество информации получилось наиболее близким к энтропии источника.